



«Μηχανική Μάθηση σε Πολυμεσικά Δεδομένα»

AI-Powered Museum Navigation for the Visually Impaired

Ελπίδα Γκούβρα (mtn2504)

Χαντάβα Στέλλα (mtn2528)

Περίληψη

Η παρούσα εργασία παρουσιάζει την ανάπτυξη ενός συστήματος υποβοηθούμενης περιήγησης σε πινακοθήκες για άτομα με προβλήματα όρασης, το οποίο μετατρέπει την εικόνα ενός έργου τέχνης σε εκφραστική προφορική περιγραφή. Το σύστημα υλοποιεί μια πολυτροπική ροή: το προεκπαιδευμένο μοντέλο όρασης-γλώσσας BLIP προσαρμόζεται (fine-tuning) στο καλλιτεχνικό πεδίο με χρήση του συνόλου δεδομένων Artpedia για την παραγωγή περιγραφών, οι οποίες στη συνέχεια εμπλουτίζονται με μεταδεδομένα και αποδίδονται ως ομιλία μέσω σύνθεσης φωνής με αυτόματη επιλογή χροιάς. Η ποιότητα των περιγραφών αξιολογήθηκε με τις μετρικές BLEU-4 και CIDEr, ενώ η ανθεκτικότητα του μοντέλου εκτός πεδίου εξετάστηκε zero-shot στο σύνολο VizWiz, που περιλαμβάνει φωτογραφίες τραβηγμένες από τυφλούς χρήστες. Η προσαρμογή βελτίωσε σημαντικά την απόδοση στο καλλιτεχνικό πεδίο, αναδεικνύοντας ταυτόχρονα τον συμβιβασμό ανάμεσα στην εξειδίκευση και τη γενίκευση σε ρεαλιστικές συνθήκες. Με βάση τα ευρήματα, προτείνεται ως μελλοντική κατεύθυνση ο εμπλουτισμός των δεδομένων εκπαίδευσης με συνθετικές εικόνες που προσομοιώνουν πραγματικές συνθήκες λήψης.

1 Εισαγωγή

Σε μία πινακοθήκη, η εμπειρία του επισκέπτη βασίζεται πρωτίστως στο συναίσθημα και τις σκέψεις που γεννά η οπτική επαφή με το έκθεμα. Ένα έργο τέχνης επικοινωνεί μηνύματα μέσα από το χρώμα, τις μορφές, τις συνθέσεις και τον κατάλληλο φωτισμό. Για τα άτομα με προβλήματα όρασης, ωστόσο, η εμπειρία αυτή διαφέρει, καθώς η σύλληψη των μηνυμάτων που προσπαθούν να μεταδώσουν τα εκθέματα πρέπει να γίνει μέσω άλλων αισθήσεων αντί της όρασης. Οι παραδοσιακές λύσεις, όπως οι ηχητικοί οδηγοί ή οι περιγραφές από συνοδό, είναι χρήσιμες αλλά περιορισμένες, καθώς απαιτούν εκ των προτέρων προετοιμασία για κάθε έργο με αποτέλεσμα να μην κλιμακώνονται εύκολα. Η πρόοδος που έχει σημειωθεί τα τελευταία χρόνια στη βαθιά μάθηση προσφέρει νέες δυνατότητες για την αντιμετώπιση του προβλήματος αυτού. Τα μοντέλα όρασης-γλώσσας (vision-language models, VLMs) είναι πλέον σε θέση να παράγουν αυτόματα περιγραφές εικόνων σε φυσική γλώσσα, ενώ η σύγχρονη τεχνολογία σύνθεσης ομιλίας (text-to-speech, TTS) μπορεί να μετατρέψει το κείμενο αυτό σε φυσική και εκφραστική ομιλία. Ο συνδυασμός των δύο τεχνολογιών ανοίγει τον δρόμο σε συστήματα που μπορούν να γενικεύσουν και να παράξουν ηχητικές περιγραφές για οποιοδήποτε έκθεμα χωρίς την ανάγκη χειροκίνητης προετοιμασίας.

Στο πλαίσιο της παρούσας εργασίας αναπτύχθηκε ο κορμός της αρχιτεκτονικής ενός συστήματος υποβοηθούμενης περιήγησης σε πινακοθήκες για άτομα με προβλήματα όρασης. Το σύστημα υλοποιεί

μια πολυτροπική ροή τριών σταδίων: από την εικόνα ενός έργου τέχνης παράγεται μια περιγραφή σε φυσική γλώσσα, η οποία εμπλουτίζεται με δομημένη σημασιολογική πληροφορία και, στη συνέχεια, αποδίδεται ως εκφραστική ομιλία. Για το πρώτο στάδιο αξιοποιείται το προεκπαιδευμένο μοντέλο BLIP [1], το οποίο προσαρμόζεται μέσω fine-tuning στο σύνολο δεδομένων Artpedia [2], που περιέχει πίνακες ζωγραφικής και αντίστοιχες περιγραφές, προκειμένου να αποδώσει καλλιτεχνική χροιά στις περιγραφές του. Η ποιότητα των παραγόμενων περιγραφών αποτιμάται με τις μετρικές BLEU [3] και CIDEr [4], ενώ η ικανότητα γενίκευσης του μοντέλου σε ρεαλιστικές συνθήκες αξιολογείται με το σύνολο δεδομένων VizWiz [5], το οποίο περιλαμβάνει φωτογραφίες τραβηγμένες από τυφλούς χρήστες. Για το στάδιο της μετατροπής σε ομιλία αξιοποιείται έτοιμο σύστημα TTS, το οποίο χρησιμοποιεί δύο διαφορετικές χροίες αφήγησης ανάλογα με τη χρονολογία του έργου: τα έργα που χρονολογούνται πριν το 1800 αποδίδονται με πιο ήρεμη χροιά, ενώ τα έργα από το 1800 και έπειτα με πιο εκφραστική.

2 Θεωρητικό Υπόβαθρο

Η παρούσα εργασία βασίζεται σε σύγχρονες τεχνικές βαθιάς μάθησης που συνδυάζουν την όραση υπολογιστών με την επεξεργασία φυσικής γλώσσας. Θεμέλιο των τεχνικών αυτών αποτελεί η αρχιτεκτονική Transformer [6], η οποία εισήγαγε τον μηχανισμό αυτο-προσοχής (self-attention). Ο μηχανισμός αυτός επιτρέπει στο μοντέλο να σταθμίζει τη σημασία κάθε στοιχείου μιας ακολουθίας σε σχέση με όλα τα υπόλοιπα, καταργώντας την ανάγκη για επαναλαμβανόμενα (recurrent) ή συνελικτικά (convolutional) δίκτυα και επιτρέποντας την παράλληλη επεξεργασία. Αρχικά αναπτύχθηκε για εργασίες επεξεργασίας γλώσσας, αλλά η επιτυχία του οδήγησε στην επέκτασή του και στον τομέα της όρασης. Η επέκταση αυτή υλοποιήθηκε με το Vision Transformer (ViT) [7], το οποίο εφαρμόζει την ίδια λογική σε εικόνες: η εικόνα διαιρείται σε μικρά τμήματα (patches) σταθερού μεγέθους, τα οποία αντιμετωπίζονται ως ακολουθία και τροφοδοτούνται στον Transformer με τον ίδιο τρόπο που τροφοδοτούνται οι λέξεις ενός κειμένου. Το γεγονός αυτό αποτέλεσε καθοριστικό βήμα για την ανάπτυξη πολυτροπικών (multimodal) μοντέλων που διαχειρίζονται παράλληλα τόσο εικόνες όσο και κείμενο. Το σύστημα που αναπτύχθηκε στην παρούσα εργασία ακολουθεί μια πολυτροπική ροή δύο σταδίων: αρχικά μετατρέπει μια εικόνα σε περιγραφικό κείμενο (vision-to-text) και στη συνέχεια μετατρέπει το κείμενο αυτό σε ομιλία (text-to-speech).

2.1 Παραγωγή Περιγραφών Εικόνων (Vision-to-Text)


Η παραγωγή περιγραφών εικόνων (image captioning) είναι η εργασία της αυτόματης δημιουργίας μιας περιγραφής σε φυσική γλώσσα που αποδίδει το περιεχόμενο μιας εικόνας. Αποτελεί χαρακτηριστικό παράδειγμα πολυτροπικής εργασίας, καθώς απαιτεί τόσο την κατανόηση του οπτικού περιεχομένου όσο και την παραγωγή συνεκτικού κειμένου. Τα σύγχρονα συστήματα image captioning ακολουθούν τυπικά ένα σχήμα κωδικοποιητή-αποκωδικοποιητή (encoder-decoder). Ένας οπτικός κωδικοποιητής (vision encoder) επεξεργάζεται την εικόνα και εξάγει μια αναπαράσταση των χαρακτηριστικών της, ενώ ένας αποκωδικοποιητής κειμένου (text decoder) παράγει, λέξη προς λέξη, την περιγραφή με βάση την αναπαράσταση αυτή. Με την επικράτηση της αρχιτεκτονικής Transformer, τόσο ο κωδικοποιητής όσο και ο αποκωδικοποιητής υλοποιούνται ως επί το πλείστον με μηχανισμούς προσοχής. Κυρίαρχη τάση αποτελεί επιπλέον και η μεταφορά μάθησης (transfer learning): αντί της εκπαίδευσης ενός μοντέλου από την αρχή, αξιοποιούνται μοντέλα προεκπαιδευμένα (pre-trained) σε μεγάλα σύνολα ζευγών εικόνας-κειμένου, τα οποία στη συνέχεια προσαρμόζονται σε μικρότερα, πιο εξειδικευμένα σύνολα δεδομένων. Με τον τρόπο αυτό, η γενική γνώση που έχει αποκτηθεί κατά την προεκπαίδευση μεταφέρεται στο εκάστοτε πεδίο εφαρμογής, μειώνοντας τις απαιτήσεις σε δεδομένα και υπολογιστικούς πόρους.

2.2 Μετατροπή Κειμένου σε Ομιλία (Text-to-Speech)

Η μετατροπή κειμένου σε ομιλία (text-to-speech, TTS) είναι η εργασία της σύνθεσης ηχητικού σήματος ομιλίας από γραπτό κείμενο. Οι σύγχρονες προσεγγίσεις βασίζονται σε νευρωνικά δίκτυα (neural TTS), τα οποία παράγουν φωνή που προσεγγίζει σε φυσικότητα την ανθρώπινη, αποδίδοντας ρεαλιστικό επιτονισμό και ρυθμό. Πέρα από την παραγωγή του βασικού ηχητικού σήματος της φωνής, σημαντικό ρόλο στη φυσικότητα του αποτελέσματος παίζει ο έλεγχος των προσωδιακών χαρακτηριστικών (prosody), όπως ο τόνος (pitch), ο ρυθμός ομιλίας (rate) και η ένταση (volume). Για τον σκοπό αυτό χρησιμοποιείται το πρότυπο Speech Synthesis Markup Language (SSML) [8], μια γλώσσα σήμανσης βασισμένη σε XML που επιτρέπει την προσαρμογή των παραπάνω παραμέτρων, ώστε η παραγόμενη ομιλία να αποκτά την επιθυμητή εκφραστικότητα και χροιά.

3 Μεθοδολογία

Το προτεινόμενο σύστημα υλοποιεί μια πολυτροπική ροή επεξεργασίας που μετατρέπει την εικόνα ενός έργου τέχνης σε εκφραστική προφορική περιγραφή, μέσα από τρία διαδοχικά στάδια. Στο πρώτο στάδιο, ένα προσαρμοσμένο μοντέλο όρασης-γλώσσας δέχεται ως είσοδο την εικόνα ενός πίνακα και παράγει μια περιγραφή του οπτικού του περιεχομένου σε φυσική γλώσσα (vision-to-text). Στο δεύτερο στάδιο, η περιγραφή αυτή εμπλουτίζεται με δομημένη σημασιολογική πληροφορία (structured semantics): πέρα από το ίδιο το κείμενο, συγκεντρώνονται μεταδεδομένα του έργου, όπως ο τίτλος, η χρονολογία και η καλλιτεχνική περίοδος, καθώς και μια προτεινόμενη χροιά αφήγησης. Στο τρίτο στάδιο, το εμπλουτισμένο κείμενο αποδίδεται ως ομιλία (text-to-speech), με προσαρμογή των προσωδιακών χαρακτηριστικών ανάλογα με την προτεινόμενη χροιά.



Σχήμα 1: Αρχιτεκτονική του προτεινόμενου συστήματος: η πολυτροπική ροή τριών σταδίων από την εικόνα στην εκφραστική ομιλία.

3.1 Δεδομένα Εκπαίδευσης

Για την εκπαίδευση και την αξιολόγηση του VLM χρησιμοποιήθηκε το σύνολο δεδομένων Artpedia [2], το οποίο περιέχει 2.930 πίνακες ζωγραφικής που καλύπτουν χρονικά την περίοδο από τον 13ο έως τον 21ο αιώνα. Κάθε έργο συνοδεύεται από έναν τίτλο, τη χρονολογία του και ένα σύνολο προτάσεων που το περιγράφουν. Το χαρακτηριστικό που καθιστά το Artpedia κατάλληλο για την παρούσα εργασία είναι ότι κάθε πρόταση είναι επισημειωμένη με βάση τον ρόλο της: ως οπτική πρόταση (visual sentence), όταν περιγράφει το ορατό περιεχόμενο του έργου, ή ως πρόταση πλαισίου (contextual sentence), όταν αναφέρεται σε ιστορικές, βιογραφικές ή άλλες πληροφορίες που δεν δύνανται να εξαχθούν απευθείας από την εικόνα. Το σύνολο διατίθεται ήδη χωρισμένο σε υποσύνολα εκπαίδευσης (train), επικύρωσης (validation) και ελέγχου (test). Για την εκπαίδευση και την αξιολόγηση αξιοποιήθηκαν μόνο οι οπτικές προτάσεις (visual sentences) κάθε έργου, ενώ οι προτάσεις πλαισίου αγνοήθηκαν. Η εκπαίδευση του μοντέλου σε προτάσεις πλαισίου θα το ωθούσε

να «εικάζει» πληροφορίες που δεν προκύπτουν από την εικόνα (όπως ιστορικά γεγονότα ή το όνομα του καλλιτέχνη), οδηγώντας σε παραγωγή αναξιόπιστων περιγραφών (hallucination).

Οι εικόνες του Artpedia διανέμονται μέσω συνδέσμων (URLs) προς εξωτερική πηγή. Για τον λόγο αυτό αναπτύχθηκε μια διαδικασία προεπεξεργασίας που ανακτά τις εικόνες, τις αποθηκεύει τοπικά και δημιουργεί ένα αρχείο καταγραφής (manifest) που αντιστοιχίζει κάθε εικόνα στις αντίστοιχες περιγραφές. Κατά την ανάκτηση χρησιμοποιήθηκαν εκδοχές των εικόνων μειωμένης ανάλυσης (thumbnails), ώστε να περιοριστεί ο όγκος των δεδομένων και ο χρόνος ανάκτησης, ενώ η διαδικασία σχεδιάστηκε ώστε να είναι ανθεκτική σε σφάλματα δικτύου και να μπορεί να συνεχίζει από το σημείο διακοπής της. Έργα των οποίων η εικόνα δεν ήταν διαθέσιμη παραλείφθηκαν.

Η επισημείωση του Artpedia σε οπτικές και πλαισιακές προτάσεις δεν είναι απολύτως ακριβής: μέρος των προτάσεων που φέρουν την ετικέτα της οπτικής περιέχει στην πραγματικότητα πληροφορίες πλαίσιου. Για τον λόγο αυτό εφαρμόστηκε ένα επιπλέον στάδιο καθαρισμού βασισμένο σε κανόνες (rule-based). Κάθε περιγραφή αναλύεται στις επιμέρους προτάσεις της και αφαιρούνται όσες ταιριάζουν σε μοτίβα απόδοσης (π.χ. painting by), προέλευσης (π.χ. now in) ή καταλογογράφησης (π.χ. χρονολογίες της μορφής in 18XX). Για παράδειγμα, η πρόταση «Madonna with Child and six Angels is a Madonna painting by Gothic artist Duccio di Buoninsegna» αφαιρείται, καθώς αποδίδει το έργο σε συγκεκριμένο καλλιτέχνη χωρίς να περιγράφει το ορατό περιεχόμενο. Συνολικά αφαιρέθηκε περίπου το 8% των προτάσεων, ενώ τα έργα των οποίων η περιγραφή απέμεινε κενή εξαιρέθηκαν· το σύνολο εκπαίδευσης περιορίστηκε από 2.150 σε 1.935 έργα και τα σύνολα επικύρωσης και ελέγχου σε 286 και 296 έργα αντίστοιχα. Ο καθαρισμός εφαρμόστηκε ομοιόμορφα και στα τρία υποσύνολα, ώστε η εκπαίδευση και η αξιολόγηση να στηρίζονται στην ίδια καθαρισμένη βάση.

3.2 Μοντέλο και Διαδικασία Εκπαίδευσης

Ως βασικό μοντέλο για την παραγωγή περιγραφών επιλέχθηκε το BLIP (Bootstrapping Language-Image Pre-training) [1], στην προεκπαιδευμένη για την εργασία παραγωγής περιγραφών εκδοχή. Το μοντέλο αποτελείται από έναν οπτικό κωδικοποιητή (vision encoder), βασισμένο σε αρχιτεκτονική Vision Transformer, ο οποίος εξάγει τα οπτικά χαρακτηριστικά της εικόνας, και έναν αποκωδικοποιητή κειμένου (text decoder), ο οποίος παράγει την περιγραφή. Η πρόσβαση στο μοντέλο και στους αντίστοιχους επεξεργαστές εικόνας και κειμένου έγινε μέσω της βιβλιοθήκης LAVIS [9], η οποία παρέχει προεκπαιδευμένα μοντέλα όρασης-γλώσσας καθώς και εργαλεία για την προσαρμογή και την αξιολόγησή τους. Δεδομένου του περιορισμένου μεγέθους του συνόλου εκπαίδευσης, η πλήρης επανεκπαίδευση όλων των παραμέτρων του μοντέλου θα ενείχε υψηλό κίνδυνο υπερπροσαρμογής (overfitting). Για τον λόγο αυτό υιοθετήθηκε στρατηγική μερικής προσαρμογής (partial fine-tuning): ο οπτικός κωδικοποιητής διατηρήθηκε πλήρως παγωμένος (frozen), αξιοποιώντας τις οπτικές αναπαραστάσεις που έχει ήδη μάθει κατά την προεκπαίδευση, και η εκπαίδευση περιορίστηκε στο τελευταίο στρώμα του αποκωδικοποιητή κειμένου μαζί με την κεφαλή πρόβλεψης λέξεων (10.1 εκατομμύρια παράμετροι). Η εκπαίδευση πραγματοποιήθηκε με τον αλγόριθμο βελτιστοποίησης AdamW. Για τη μείωση των απαιτήσεων σε μνήμη και την επιτάχυνση της εκπαίδευσης χρησιμοποιήθηκε αριθμητική μειωμένης ακρίβειας (mixed-precision, fp16). Η παρακολούθηση της εκπαιδευτικής διαδικασίας, καθώς και η καταγραφή των υπερπαραμέτρων και των μετρικών κάθε εκτέλεσης, έγινε με το εργαλείο MLflow [10]. Για την αποφυγή της υπερπροσαρμογής και την επιλογή του κατάλληλου σημείου τερματισμού, σε κάθε εποχή (epoch) υπολογιζόταν η απώλεια διασταυρούμενης εντροπίας (Cross-Entropy Loss) τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο επικύρωσης (validation set). Εφαρμόστηκε μηχανισμός πρόωρου τερματισμού (early stopping): η εκπαίδευση διακοπτόταν όταν η απώλεια στο σύνολο επικύρωσης έπαυε να βελτιώνεται για έναν προκαθορισμένο αριθμό διαδοχικών εποχών, διατηρώντας ως τελικό το μοντέλο με τη χαμηλότερη απώλεια επικύρωσης.

Πίνακας 1: Υπερπαράμετροι εκπαίδευσης

Υπερπαράμετρος	Τιμή
Optimizer	AdamW
Learning rate	1×10^{-5}
Batch size	4
Epochs (μέγιστες)	20
Εκπαιδευσιμα στρώματα (unfreeze-last-n)	1
Early stopping patience	2
Mixed precision	fp16

3.3 Μετατροπή σε Ομιλία

Το δεύτερο σκέλος του συστήματος μετατρέπει την παραγόμενη περιγραφή σε εκφραστική ομιλία. Πριν από τη σύνθεση, το caption εμπλουτίζεται προαιρετικά με τα διαθέσιμα μεταδεδομένα του έργου (τίτλος, χρονολογία, καλλιτεχνική περίοδος): όταν αυτά υπάρχουν, προηγείται μια σύντομη εισαγωγή πριν από την περιγραφή, ενώ διαφορετικά εκφωνείται μόνο η περιγραφή. Η σύνθεση ομιλίας προσαρμόζεται στο ύφος κάθε έργου μέσω μιας προτεινόμενης χροιάς αφήγησης (suggested tone), που επιλέγεται αυτόματα με βάση τη χρονολογία: τα έργα πριν από το 1800 αποδίδονται με μια πιο ήρεμη χροιά, ενώ τα νεότερα με μια πιο ζωντανή. Κάθε χροιά αντιστοιχεί σε ένα διαφορετικό προφίλ φωνής και προσωδιακών παραμέτρων — συγκεκριμένη φωνή, ρυθμός ομιλίας (rate), τόνος (pitch) και ένταση (volume). Ενδεικτικά, η ήρεμη χροιά αξιοποιεί μια βρετανική γυναικεία φωνή με ελαφρώς μειωμένο ρυθμό και χαμηλότερο τόνο, αποδίδοντας μια πιο μετρημένη αφήγηση κατάλληλη για παλαιότερα έργα, ενώ η ζωντανή χροιά αξιοποιεί μια αμερικανική φωνή με ελαφρώς αυξημένο τόνο και ένταση, για μια πιο θερμή απόδοση. Η υλοποίηση στηρίχθηκε στη βιβλιοθήκη ανοικτού κώδικα edge-tts [11], η οποία παρέχει πρόσβαση στις νευρωνικές φωνές της υπηρεσίας σύνθεσης ομιλίας της Microsoft (Azure Neural TTS) [12] χωρίς να απαιτείται κλειδί API ή λογαριασμός. Οι προσωδιακές παράμετροι κάθε χροιάς αποδίδονται μέσω του προτύπου SSML [8], μιας γλώσσας σήμανσης βασισμένης σε XML που επιτρέπει τον λεπτομερή έλεγχο των χαρακτηριστικών της φωνής. Το παραγόμενο αποτέλεσμα αποθηκεύεται για κάθε έργο ως ηχητικό αρχείο μορφής MP3.

Πίνακας 2: Χαρακτηριστικά φωνής και προσωδιακές παράμετροι ανά χροιά αφήγησης

	calm (έργα πριν το 1800)	engaging (έργα από το 1800)
Φωνή (voice)	en-GB-SoniaNeural	en-US-JennyNeural
Προφορά	Βρετανική, γυναικεία	Αμερικανική, γυναικεία
Ρυθμός (rate)	−5%	−2%
Τόνος (pitch)	−2 Hz	+4 Hz
Ένταση (volume)	+0%	+3%

4 Αποτελέσματα

Η αξιολόγηση της προσαρμογής πραγματοποιήθηκε με δύο διαφορετικές μετρικές image captioning: το BLEU-4 [3], που μετρά την επικάλυψη ακολουθιών τεσσάρων λέξεων μεταξύ της παραγόμενης περιγραφής και των περιγραφών αναφοράς, και το CIDEr [4], που σταθμίζει τις λέξεις ανάλογα με τη διακριτική τους αξία. Και στις δύο μετρικές, υψηλότερη τιμή υποδηλώνει καλύτερη ποιότητα. Στο πλαίσιο της εργασίας συγκρίθηκε το προεκπαιδευμένο μοντέλο (pretrained) με το προσαρμοσμένο (fine-tuned), τόσο στο σύνολο ελέγχου του Artpedia όσο και σε μέρος του συνόλου επικύρωσης του VizWiz χωρίς περαιτέρω εκπαίδευση (zero-shot) για την αξιολόγηση της ανθεκτικότητας εκτός πεδίου.

4.1 Συμπεριφορά Εκπαίδευσης

Η εκπαίδευση τερματίστηκε πρόωρα (early stopping) στην 10η εποχή, με το βέλτιστο μοντέλο να επιτυγχάνεται στην 8η, όπου η απώλεια επικύρωσης (validation loss) έλαβε την ελάχιστη τιμή της (5.153). Παρατηρήθηκε ότι, ενώ η απώλεια εκπαίδευσης (training loss) μειωνόταν σταθερά (από 5.345 σε 4.793), η απώλεια επικύρωσης σταθεροποιήθηκε και κατόπιν άρχισε να αυξάνεται μετά την 8η εποχή, ένδειξη ότι το μοντέλο άρχισε να υπερπροσαρμόζεται και ότι ο μηχανισμός πρόωρου τερματισμού λειτούργησε όπως αναμενόταν.

4.2 Αξιολόγηση στο σύνολο δεδομένων Artpedia

4.2.1 Ποσοτική Ανάλυση


Πίνακας 3: Αξιολόγηση στο σύνολο ελέγχου του Artpedia

Μοντέλο	BLEU-4	CIDEr
Pretrained	0.013	0.027
Fine-tuned	0.034	0.062

Η προσαρμογή στο καλλιτεχνικό πεδίο βελτίωσε αισθητά την απόδοση: το BLEU-4 υπερδιπλασιάστηκε (από 0.013 σε 0.034) και το CIDEr αυξήθηκε κατά παρόμοιο ποσοστό (από 0.027 σε 0.062). Ωστόσο, οι απόλυτες τιμές παρέμειναν χαμηλές, γεγονός που αποδίδεται στη φύση των δεδομένων: οι περιγραφές αναφοράς του Artpedia είναι εκτενείς και λεπτομερείς, ενώ το μοντέλο παράγει συντομότερες, πιο γενικές περιγραφές. Η απόκλιση αυτή στο μήκος και στη λεπτομέρεια τιμωρείται από τις μετρικές επικάλυψης. Παρά τις χαμηλές απόλυτες τιμές, η σχετική βελτίωση επιβεβαιώνει ότι η προσαρμογή προσέφερε ουσιαστική γνώση του πεδίου.

4.2.2 Ποιοτική Ανάλυση

Η ποιοτική εξέταση των παραγόμενων περιγραφών επιβεβαιώνει ότι η προσαρμογή βελτίωσε αισθητά την ποιότητα και τη λεπτομέρεια των περιγραφών, παρά τις χαμηλές απόλυτες τιμές των μετρικών. Στον Πίνακα 4 παρουσιάζονται δύο παραδείγματα από το σύνολο ελέγχου, μαζί με τις αντίστοιχες εικόνες (Σχήμα 2). Και στα δύο παραδείγματα, το προεκπαιδευμένο μοντέλο παράγει σύντομες και γενικές περιγραφές («a painting of boats in the water near a dock», «a painting of people and animals in a field»), ενώ το προσαρμοσμένο μοντέλο αποδίδει πιο πλούσιες και εύστοχες περιγραφές. Στο πρώτο έργο, το προσαρμοσμένο μοντέλο αναγνωρίζει όχι μόνο το λιμάνι αλλά και τη φωτεινή ατμόσφαιρα της αυγής και τις προβλήτες στο προσκήνιο. Στο δεύτερο, εντοπίζει ορθά τις τρεις γυναικείες μορφές, την ομπρέλα και τις αγελάδες στο τοπίο. Παρατηρούνται ωστόσο και ορισμένες παραλείψεις, όπως η μικρή αγρότισσα και ο σκύλος στο δεύτερο έργο. Μια πιθανή εξήγηση είναι το όριο μήκους της παραγωγής (40 tokens), που περιορίζει την έκταση της περιγραφής και ωθεί το μοντέλο να εστιάσει στα πιο εμφανή στοιχεία της σύνθεσης. Συνολικά, τα παραδείγματα επιβεβαιώνουν ότι η προσαρμογή οδήγησε σε περιγραφές πιο κοντά στο ύφος και στο επίπεδο λεπτομέρειας του καλλιτεχνικού πεδίου.



(α') Gloucester Harbor (William Morris Hunt, 1877)



(β') Young Ladies of the Village (Gustave Courbet, 1852)


Σχήμα 2: Τα δύο έργα του συνόλου ελέγχου που χρησιμοποιούνται στην ποιοτική ανάλυση.

Πίνακας 4: Ποιοτική σύγκριση περιγραφών σε δύο έργα του συνόλου ελέγχου

Έργο	Annotation	Pretrained	Fine-tuned
(α')	Done in oil on canvas, the impressionist painting depicts morning in the harbor of Gloucester.	A painting of boats in the water near a dock.	The painting depicts the harbor at dawn, with the docks in the foreground.
(β')	In the centre three young women offer a barefoot peasant girl something to eat. One holds an umbrella against the sun. A dog stands behind the trio, whilst to the right two cows graze in a hilly landscape.	A painting of people and animals in a field.	The painting depicts three women in a field with cows, one is holding an umbrella and the other is standing on a hill.

4.2.3 Οπτικοποίηση Αναπαραστάσεων

Στο Σχήμα 3 παρουσιάζεται η προβολή t-SNE των αναπαραστάσεων του αποκωδικοποιητή για το προεκπαιδευμένο και το προσαρμοσμένο μοντέλο, με χρωματικό κωδικό ανά αιώνα. Και στις δύο περιπτώσεις οι αναπαραστάσεις παρουσιάζουν οργάνωση με βάση τη χρονική περίοδο των έργων, γεγονός που υποδηλώνει ότι το μοντέλο διατηρεί μια συνεκτική εσωτερική δομή. Καθώς ο οπτικός κωδικοποιητής παρέμεινε παγωμένος και εκπαιδεύτηκε μόνο ένα στρώμα του αποκωδικοποιητή, η συνολική δομή των αναπαραστάσεων δεν μεταβάλλεται αισθητά μεταξύ των δύο μοντέλων.



Σχήμα 3: Σύγκριση αναπαράστασης pretrained και fine-tuned μοντέλου.

4.3 Αξιολόγηση Ανθεκτικότητας στο σύνολο δεδομένων VizWiz

Πίνακας 5: Αξιολόγηση zero-shot στο VizWiz

Μοντέλο	BLEU-4	CIDEr
Pretrained	0.176	0.298
Fine-tuned	0.117	0.265

Η αξιολόγηση των δύο μοντέλων σε 200 εικόνες του συνόλου επικύρωσης του VizWiz ανέδειξε πως το προσαρμοσμένο μοντέλο αποδίδει χειρότερα από το προεκπαιδευμένο, με το BLEU-4 να μειώνεται από 0.176 σε 0.117. Το αποτέλεσμα ήταν αναμενόμενο καθώς η προσαρμογή στο καλλιτεχνικό πεδίο εξειδίκευσε το μοντέλο στις περιγραφές έργων τέχνης, μειώνοντας την ικανότητά του να γενικεύει σε καθημερινές, «θορυβώδεις» φωτογραφίες όπως αυτές του VizWiz. Αναδεικνύοντας το συμβιβασμό (trade-off) ανάμεσα στην εξειδίκευση και στη γενική ανθεκτικότητα ενός τέτοιου συστήματος.

5 Συμπεράσματα

Στην παρούσα εργασία αναπτύχθηκε ο κορμός ενός συστήματος υποβοηθούμενης περιήγησης σε πινακοθήκες για άτομα με προβλήματα όρασης, το οποίο μετατρέπει την εικόνα ενός έργου τέχνης σε εκφραστική προφορική περιγραφή μέσα από μια πολυτροπική ροή τριών σταδίων. Για το οπτικό σκέλος, το προεκπαιδευμένο μοντέλο BLIP προσαρμόστηκε στο καλλιτεχνικό πεδίο με στρατηγική μερικής προσαρμογής (partial fine-tuning), ενώ το παραγόμενο κείμενο εμπλουτίστηκε με δομημένη σημασιολογική πληροφορία και αποδόθηκε ως ομιλία με αυτόματη επιλογή χροιάς. Τα αποτελέσματα ανέδειξαν δύο βασικά ευρήματα. Πρώτον, η προσαρμογή στο Artpedia βελτίωσε αισθητά την ποιότητα των περιγραφών στο πεδίο της τέχνης, με το BLEU-4 και το CIDEr να υπερδιπλασιάζονται σε σχέση με το προεκπαιδευμένο μοντέλο, και με την ποιοτική ανάλυση να επιβεβαιώνει πιο πλούσιες και εύστοχες περιγραφές. Δεύτερον, η αξιολόγηση zero-shot στο VizWiz αποκάλυψε τον αναμενόμενο συμβιβασμό (trade-off) της εξειδίκευσης: το προσαρμοσμένο μοντέλο, ενώ υπερτερεί στο καλλιτεχνικό πεδίο, έχασε μέρος της ικανότητάς του να γενικεύει σε ρεαλιστικές, «θορυβώδεις» εικόνες. Το εύρημα αυτό είναι ιδιαίτερα σημαντικό για την πρακτική ανάπτυξη του συστήματος, καθώς σε πραγματικές συνθήκες ο χρήστης με προβλήματα όρασης θα φωτογραφίζει τα έργα κάτω από ακριβώς τέτοιες μη ιδανικές συνθήκες λήψης — θολές, ατελώς πλαισιωμένες ή κακοφωτισμένες εικόνες.

Εδώ έγκειται και ο κύριος περιορισμός της παρούσας προσέγγισης: το σύνολο εκπαίδευσης Artpedia αποτελείται από «καθαρές», υψηλής ποιότητας εικόνες έργων, οι οποίες δεν αντικατοπτρίζουν τις πραγματικές συνθήκες λήψης από έναν τυφλό χρήστη. Το μοντέλο, επομένως, εκπαιδεύεται σε ιδανικές συνθήκες που δεν συναντώνται στην πράξη. Ως κύρια κατεύθυνση μελλοντικής βελτίωσης προτείνεται η αντιμετώπιση αυτού του κενού μέσω της παραγωγής συνθετικών δεδομένων. Συγκεκριμένα, με χρήση ενός μοντέλου διάχυσης (diffusion model) θα μπορούσαν να παραχθούν συνθετικές εκδοχές των έργων του Artpedia που ενσωματώνουν τα χαρακτηριστικά των εικόνων του VizWiz — θόρυβο, ατελή πλαίσια, μη ιδανικό φωτισμό — ώστε να προσομοιώνουν φωτογραφίες πινάκων τραβηγμένες από άτομα με προβλήματα όρασης. Καθώς η επιτυχία ενός τέτοιου εγχειρήματος προϋποθέτει μεγαλύτερο όγκο δεδομένων, και δεδομένης της έλλειψης διαθέσιμων συνόλων που να συνδυάζουν έργα τέχνης με ρεαλιστικές συνθήκες λήψης, η πρόταση είναι ο εμπλουτισμός του Artpedia με τα συνθετικά αυτά δεδομένα. Με τον τρόπο αυτό, το μοντέλο θα μπορούσε να εκπαιδευτεί σε μια κατανομή πιο κοντινή στην πραγματική χρήση, γεφυρώνοντας το χάσμα ανάμεσα στην εξειδίκευση στο καλλιτεχνικό πεδίο και στην ανθεκτικότητα σε πραγματικές συνθήκες.

Αναφορές

- [1] J. Li, D. Li, C. Xiong, and S. Hoi, “Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation,” in *ICML*, 2022.
- [2] M. Stefanini, M. Cornia, L. Baraldi, M. Corsini, and R. Cucchiara, “Artpedia: A New Visual-Semantic Dataset with Visual and Contextual Sentences,” in *Proceedings of the International Conference on Image Analysis and Processing*, 2019.
- [3] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “BLEU: A method for automatic evaluation of machine translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, (Philadelphia, Pennsylvania, USA), pp. 311–318, Association for Computational Linguistics, 2002.
- [4] R. Vedantam, C. L. Zitnick, and D. Parikh, “CIDEr: Consensus-based image description evaluation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4566–4575, 2015.
- [5] D. Gurari, Y. Zhao, M. Zhang, and N. Bhattacharya, “Captioning images taken by people who are blind,” *CoRR*, vol. abs/2002.08565, 2020.
- [6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 5998–6008, 2017.
- [7] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [8] World Wide Web Consortium (W3C), “Speech synthesis markup language (SSML) version 1.1,” tech. rep., W3C Recommendation, 2010. <https://www.w3.org/TR/speech-synthesis11/>.
- [9] D. Li, J. Li, H. Le, G. Wang, S. Savarese, and S. C. H. Hoi, “Lavis: A library for language-vision intelligence,” 2022.
- [10] Databricks, “MLflow: An open source platform for the machine learning lifecycle.” <https://mlflow.org>. Accessed: 2026-06-19.

- [11] Andrew (rany2), “edge-tts: A Python module to use Microsoft Edge’s online text-to-speech service.” <https://github.com/rany2/edge-tts>. Accessed: 2026-06-19.
- [12] Microsoft, “Text to speech – Azure AI Speech neural voices.” <https://learn.microsoft.com/azure/ai-services/speech-service/text-to-speech>, 2026. Accessed: 2026-06-19.

A’ Κώδικας

Ο πλήρης πηγαίος κώδικας της εργασίας διατίθεται δημόσια μέσω ψηφιακού αποθετηρίου στον ακόλουθο GitHub σύνδεσμο:

<https://github.com/GElpida/mscai-multimodal-project.git>